

**KELOMPOK 11**  
**Dylan Putra Brataatmadja - 2440083241**  
**Freidrich Lim - 2440004924**  
**Gilbert - 2440013430**  
**Hanrich Marcius - 2440013922**

**LATAR BELAKANG**

Diabetes umumnya sama dengan penyakit "diabetes melitus". Diabetes Melitus (DM) merupakan penyakit kronis yang terjadi ketika pankreas tidak memproduksi insulin yang cukup atau ketika tubuh tidak dapat secara efektif menggunakan insulin yang dihasilkan. Insulin adalah hormon yang mengatur gula darah. Diabetes yang tidak terkontrol dari waktu ke waktu menyebabkan kerusakan serius pada banyak sistem tubuh, khususnya saraf dan pembuluh darah (WHO, 2011). Diabetes merupakan suatu kelompok penyakit yang pada umumnya memiliki suatu kesamaan gejala, yaitu buang air kecil dan rasa haus yang berlebihan.

Diabetes merupakan penyakit yang sudah umum ditemukan pada banyak orang baik orang tua maupun remaja. Ada banyak faktor yang dapat menyebabkan diabetes mulai dari pola hidup yang kurang baik, usia, maupun dari keturunan. Diabetes dapat memicu komplikasi ke penyakit lainnya, seperti penyakit jantung, fungsi penglihatan berkurang, penyakit ginjal hingga amputasi pada bagian tubuh yang diakibatkan banyaknya kandungan gula pada darah. Diabetes tidak memiliki obat yang dapat menyembuhkan, namun ada beberapa cara yang dapat dilakukan untuk meminimalisir efek dari diabetes, seperti mengurangi berat badan, memakan makanan yang sehat, aktif berolahraga, dan treatment diabetes seperti suntik insulin.

*Centers Disease Control and Prevention* mengestimasi 8 dari 10 pengidap diabetes tidak sadar akan resiko yang diakibatkan oleh diabetes jika pengidap tidak mengetahui jika ia terkena diabetes, maka dari itu pengidap diabetes harus cepat menyadari dan ditangani agar dapat meminimalisir efek samping yang dapat diakibatkan oleh diabetes.

**RUMUSAN MASALAH**

1. apa hubungan umur dengan penyakit diabetes?
2. Apa hubungan frekuensi merokok dengan penyakit diabetes?
3. Apa hubungan jenis kelamin dengan penyakit diabetes?
4. Apa hubungan tekanan darah tinggi dengan penyakit diabetes?
5. Apa hubungan indeks kolesterol dengan penyakit diabetes?
6. Apa hubungan indeks massa tubuh (BMI) dengan penyakit diabetes??

## TUJUAN

1. Mengetahui hubungan umur dengan penyakit diabetes.
2. Mengetahui hubungan frekuensi merokok dengan penyakit diabetes.
3. Mengetahui hubungan jenis kelamin dengan penyakit diabetes.
4. Mengetahui hubungan tekanan darah tinggi dengan penyakit diabetes.
5. Mengetahui hubungan kolesterol dengan penyakit diabetes.
6. Mengetahui hubungan indeks massa tubuh (BMI) dengan penyakit diabetes.

## MANFAAT

Dari dataset yang telah kita olah kita berharap dapat menghasilkan analisis prediktif yang dapat membantu pembaca untuk mengetahui faktor-faktor yang dapat menyebabkan terjangkitnya penyakit diabetes, sehingga pembaca dapat mengetahui dari data bahwa ada beberapa faktor yang dapat meningkatkan resiko terjangkitnya diabetes.

## METODOLOGY DAN ANALISIS

### ▼ Install kaggle

```
!pip install kaggle

Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-wheels/public/simple/
Requirement already satisfied: kaggle in /usr/local/lib/python3.7/dist-packages (1.5.12)
Requirement already satisfied: python-slugify in /usr/local/lib/python3.7/dist-packages (from kaggle) (6.1.2)
Requirement already satisfied: certifi in /usr/local/lib/python3.7/dist-packages (from kaggle) (2022.5.18.1)
Requirement already satisfied: six>=1.10 in /usr/local/lib/python3.7/dist-packages (from kaggle) (1.15.0)
Requirement already satisfied: urllib3 in /usr/local/lib/python3.7/dist-packages (from kaggle) (1.24.3)
Requirement already satisfied: tqdm in /usr/local/lib/python3.7/dist-packages (from kaggle) (4.64.0)
Requirement already satisfied: requests in /usr/local/lib/python3.7/dist-packages (from kaggle) (2.23.0)
Requirement already satisfied: python-dateutil in /usr/local/lib/python3.7/dist-packages (from kaggle) (2.8.2)
Requirement already satisfied: text-unidecode>=1.3 in /usr/local/lib/python3.7/dist-packages (from python-slugify->kaggle) (1.3)
Requirement already satisfied: chardet<4,>=3.0.2 in /usr/local/lib/python3.7/dist-packages (from requests->kaggle) (3.0.4)
Requirement already satisfied: idna<3,>=2.5 in /usr/local/lib/python3.7/dist-packages (from requests->kaggle) (2.10)
```

```
[ ] ! mkdir ~/.kaggle

mkdir: cannot create directory '/root/.kaggle': File exists
```

```
[ ] ! cp kaggle.json ~/.kaggle/
```

Perlu melakukan upload API token yang didapatkan pada page profile di kaggle kemudian di upload ke drive, baris code diatas akan melakukan mount terhadap file json untuk autentikasi

```
[ ] ! chmod 600 ~/.kaggle/kaggle.json
```

Melakukan penginstallan dependensi yang diperlukan untuk mengakses data dari kaggle pada VM yang disediakan.

## Download Datasets

```
[ ] ! kaggle datasets download alexteboul/diabetes-health-indicators-dataset
```

```
Downloading diabetes-health-indicators-dataset.zip to /content
83% 5.00M/6.03M [00:01<00:00, 3.74MB/s]
100% 6.03M/6.03M [00:01<00:00, 4.50MB/s]
```

Mengunduh dataset yang akan digunakan untuk project ini yaitu dataset yang berkaitan dengan indikator penyakit diabetes

```
[ ] ! unzip diabetes-health-indicators-dataset
```

```
Archive: diabetes-health-indicators-dataset.zip
inflating: diabetes_012_health_indicators_BRFSS2015.csv
inflating: diabetes_binary_5050split_health_indicators_BRFSS2015.csv
inflating: diabetes_binary_health_indicators_BRFSS2015.csv
```

Digunakan untuk melakukan unzip terhadap file apabila file yang diunduh masih berbentuk zip

### Import library dan data loading (Dataset dan Sample data)

```
[ ] import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

Melakukan import-import library dasar yang akan digunakan untuk project, menggunakan pandas untuk melakukan proses analisis data, seaborn untuk visualisasi data dan matplotlib digunakan matplotlib untuk membantu visualisasi juga.

```
path = "diabetes_binary_health_indicators_BRFSS2015.csv"
df = pd.read_csv(path)
```

	Diabetes_binary	HighBP	HighChol	CholCheck	BMI	Smoker	Stroke	HeartDiseaseorattack	PhysActivity	Fruits	...	AnyHealthcare	NoDocbcCost	GenHlth	MentHlth	PhysHlth	DiffWalk	Sex	Age	Education	Income
0	0.0	1.0	1.0	1.0	40.0	1.0	0.0	0.0	0.0	0.0	...	1.0	0.0	5.0	18.0	15.0	1.0	0.0	9.0	4.0	3.0
1	0.0	0.0	0.0	0.0	25.0	1.0	0.0	0.0	1.0	0.0	...	0.0	1.0	3.0	0.0	0.0	0.0	0.0	7.0	6.0	1.0
2	0.0	1.0	1.0	1.0	28.0	0.0	0.0	0.0	0.0	1.0	...	1.0	1.0	5.0	30.0	30.0	1.0	0.0	9.0	4.0	8.0
3	0.0	1.0	0.0	1.0	27.0	0.0	0.0	0.0	1.0	1.0	...	1.0	0.0	2.0	0.0	0.0	0.0	0.0	11.0	3.0	6.0
4	0.0	1.0	1.0	1.0	24.0	0.0	0.0	0.0	1.0	1.0	...	1.0	0.0	2.0	3.0	0.0	0.0	0.0	11.0	5.0	4.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
253675	0.0	1.0	1.0	1.0	45.0	0.0	0.0	0.0	0.0	1.0	...	1.0	0.0	3.0	0.0	5.0	0.0	1.0	5.0	6.0	7.0
253676	1.0	1.0	1.0	1.0	18.0	0.0	0.0	0.0	0.0	0.0	...	1.0	0.0	4.0	0.0	0.0	1.0	0.0	11.0	2.0	4.0
253677	0.0	0.0	0.0	1.0	28.0	0.0	0.0	0.0	1.0	1.0	...	1.0	0.0	1.0	0.0	0.0	0.0	0.0	2.0	5.0	2.0
253678	0.0	1.0	0.0	1.0	23.0	0.0	0.0	0.0	0.0	1.0	...	1.0	0.0	3.0	0.0	0.0	0.0	1.0	7.0	5.0	1.0
253679	1.0	1.0	1.0	1.0	25.0	0.0	0.0	1.0	1.0	1.0	...	1.0	0.0	2.0	0.0	0.0	0.0	0.0	9.0	6.0	2.0

253680 rows x 22 columns

Melakukan loading data menggunakan fungsi read\_csv yang berguna untuk melakukan loading data dari file dengan format csv kedalam variabel denoan tioe dataframe

```
[ ] df.head()
```

	Diabetes_binary	HighBP	HighChol	CholCheck	BMI	Smoker	Stroke	HeartDiseaseorattack	PhysActivity	Fruits	...	AnyHealthcare	NoDocbcCost	GenHlth	MentHlth	PhysHlth	DiffWalk	Sex	Age	Education	Income
0	0.0	1.0	1.0	1.0	40.0	1.0	0.0	0.0	0.0	0.0	...	1.0	0.0	5.0	18.0	15.0	1.0	0.0	9.0	4.0	3.0
1	0.0	0.0	0.0	0.0	25.0	1.0	0.0	0.0	1.0	0.0	...	0.0	1.0	3.0	0.0	0.0	0.0	0.0	7.0	6.0	1.0
2	0.0	1.0	1.0	1.0	28.0	0.0	0.0	0.0	0.0	1.0	...	1.0	1.0	5.0	30.0	30.0	1.0	0.0	9.0	4.0	8.0
3	0.0	1.0	0.0	1.0	27.0	0.0	0.0	0.0	1.0	1.0	...	1.0	0.0	2.0	0.0	0.0	0.0	0.0	11.0	3.0	6.0
4	0.0	1.0	1.0	1.0	24.0	0.0	0.0	0.0	1.0	1.0	...	1.0	0.0	2.0	3.0	0.0	0.0	0.0	11.0	5.0	4.0

5 rows x 22 columns

Mengecek apakah data sudah muat dengan baik atau belum dengan fungsi head() yang berguna untuk menampilkan secara default 5 data teratas dari df, jika ingin mengurangi atau menambah data yang ingin ditampilkan dapat memasukan bilangan integer dalam kurung sebagai parameter. Sample data set dapat dilihat disini

## Satuan perhitungan data (Tipe data, penjelasan data set)

Perlu diketahui bahwa data disajikan dalam bilangan biner di mana

Diabetes\_binary : 0 = no diabetes 1 = diabetes

HighBP : 0 = no high BP 1 = high BP

HighChol : 0 = no high cholesterol 1 = high cholesterol

CholCheck : 0 = no cholesterol check in 5 years 1 = yes cholesterol check in 5 years

BMI : Body Mass Index

Smoker : Have you smoked at least 100 cigarettes in your entire life? [Note: 5 packs = 100 cigarettes] 0 = no 1 = yes

Stroke : (Ever told) you had a stroke. 0 = no 1 = yes

HeartDiseaseorAttack : coronary heart disease (CHD) or myocardial infarction (MI) 0 = no 1 = yes

PhysActivity : physical activity in past 30 days - not including job 0 = no 1 = yes

Fruits : Consume Fruit 1 or more times per day 0 = no 1 = yes

Veggies : Consume Vegetables 1 or more times per day 0 = no 1 = yes

HvyAlcoholConsump : (adult men >=14 drinks per week and adult women >=7 drinks per week) 0 = no 1 = yes

AnyHealthcare : Have any kind of health care coverage, including health insurance, prepaid plans such as HMO, etc. 0 = no 1 = yes

NoDocbcCost : Was there a time in the past 12 months when you needed to see a doctor but could not because of cost? 0 = no 1 = yes

GenHlth : Would you say that in general your health is: scale 1-5 1 = excellent 2 = very good 3 = good 4 = fair 5 = poor

MentHlth : days of poor mental health scale 1-30 days

PhysHlth : physical illness or injury days in past 30 days scale 1-30

DiffWalk : Do you have serious difficulty walking or climbing stairs? 0 = no 1 = yes

Sex : 0 = female 1 = male

Age : 13-level age category (\_AGE5YR see codebook) 1 = 18-24 9 = 60-64 13 = 80 or older

Education : Education level (EDUCA see codebook) scale 1-6 1 = Never attended school or only kindergarten 2 = elementary etc.

Income : Income scale (INCOME2 see codebook) scale 1-8 1 = less than 10,0005 = *lessthan*35,000 8 = \$75,000 or more

Perhitungan data penderita diabetes dan orang sehat (Proses Data dan Visualisasi Data)


```
[ ] df = df.loc[:, ['Diabetes_binary', 'HighBP', 'HighChol', 'BMI', 'Smoker', 'HeartDiseaseorAttack', 'PhysActivity', 'Fruits', 'Veggies', 'HvyAlcoholConsump', 'GenHlth', 'MentHlth', 'Sex', 'Age']]
diabet = len(df[df.Diabetes_binary == 1])
sehat = len(df[df.Diabetes_binary == 0])
print('Persentase orang sehat: {:.2f}%'.format((sehat / len(df.Diabetes_binary))*100))
print('Persentase orang yang menderita diabetes: {:.2f}%'.format((diabet / len(df.Diabetes_binary))*100))
```

Persentase orang sehat: 86.87%  
Persentase orang yang menderita diabetes: 13.93%

Block code ini digunakan untuk menghitung data orang yang menderita diabetes dan yang tidak terkena diabetes, kita dapat mencari rata-rata faktor yang mempengaruhi seseorang menderita diabetes dan melakukan kolom-kolom yang tidak diperlukan dalam analisis seperti AnyHealthcare (tentang kepemilikan asuransi), NoDocbcCost (hasil untuk konsultasi dengan dokter), Education, dan income


```
[ ] fig, ax1 = plt.subplots(1,2,figsize=(8,8))
sns.countplot(df.Diabetes_binary, ax=ax1[0])
labels = 'Yes', 'No'
df.Diabetes_binary.value_counts().plot.pie(labels = labels, autopct='%1.1f%%', shadow=True, startangle=90)
```

/local/lib/python3.7/dist-packages/seaborn/decorators.py:45: FutureWarning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positional argument will be 'data', and passing other arguments without an explicit keyword will result in an error or misinterpretation.  
tuplenameing  
Plotlib.axes.\_subplots.AxesSubplot at 0x7f642c4750e0



## Hubungan Age (umur) dengan Penyakit diabetes (Proses Data dan Visualisasi Data)

```
sns.boxplot(x = 'Diabetes_binary', y = 'Age', data = df)
plt.title('Age vs Diabetes_binary')
plt.show()
```




Disini kita dapat melihat bahwa median dari penderita diabetes lebih tinggi daripada orang yang tidak menderita diabetes di mana artinya diabetes lebih rawan diderita oleh orang yang lebih tua

```
[ ] pd.crosstab(df["Diabetes_binary"], df["Age"])
```

Age	1.0	2.0	3.0	4.0	5.0	6.0	7.0	8.0	9.0	10.0	11.0	12.0	13.0
Diabetes_binary													
0.0	5622	7458	10809	13197	15106	18077	23226	26569	27511	25636	18392	12577	14154
1.0	78	140	314	626	1051	1742	3088	4263	5733	6558	5141	3403	3209

Di atas adalah distribusi penderita diabetes pada 13 level age category, fungsi crosstab digunakan untuk menunjukan relasi 2 atau lebih variable antar 2 table

```
pd.crosstab(df.Age, df.Diabetes_binary).plot(kind="bar", figsize=(20,6))
plt.title('Distribusi Frekuensi Diabetes Terhadap Umur')
plt.xlabel('Age')
plt.ylabel('Frequency')
plt.legend(['Sehat', 'Penderita'])
plt.show()
```



Visualisasi distribusi umur penderita diabetes, dapat dilihat bahwa penderita diabetes semakin meningkat seiring umur bertambah

## Hubungan Smoker (Frekuensi Merokok) dengan Penyakit (Proses Data dan Visualisasi Data)


```
pd.crosstab(df.Smoker, df.Diabetes_binary)
```

Diabetes_binary	Smoker	
	0.0	1.0
0.0	124228	17029
1.0	94106	18317

Di atas merupakan distribusi dari penderita diabetes dan orang sehat dengan hubungannya terhadap kegiatan merokok, terlihat bahwa orang dengan diabetes lebih mungkin merokok karena jumlah penderita yang merokok lebih besar daripada penderita yang tidak merokok

```
[ ] pd.crosstab(df.Smoker, df.Diabetes_binary).plot(kind = 'bar')
plt.legend(["Sehat", "Penderita"])
plt.title("Distribusi Frekuensi Diabetes Terhadap Perokok")
```

Text(0.5, 1.0, 'Distribusi Frekuensi Diabetes Terhadap Perokok')



Di atas merupakan visualisasi dari distribusi perokok yang tidak menderita dan menderita diabetes


## Hubungan Antara Sex (Jenis Kelamin) dengan Penyakit Diabetes (Proses Data dan Visualisasi Data)

```
[ ] pd.crosstab(df.Sex,df.Diabetes_binary)
```

	Diabetes_binary	
	0.0	1.0
Sex		
0.0	123563	18411
1.0	94771	16935

Berdasarkan hubungan antara jenis kelamin dan penyakit diabetes, wanita lebih rawan terkena diabetes namun wanita juga lebih sehat dibanding kan pria, namun hal ini bisa saja terjadi karena jumlah wanita dan pria yang ikut survey berbeda

```
▶ pd.crosstab(df.Sex,df.Diabetes_binary).plot(kind="bar",figsize=(15,6))
plt.title('Distribusi Frekuensi Diabetes Terhadap Jenis Kelamin')
plt.xlabel('Sex (0 = Female, 1 = Male)')
plt.xticks(rotation=0)
plt.legend(["Sehat", "Penderita"])
plt.ylabel('Frequency')
plt.show()
```



Di atas merupakan visualisasi dari distribusi jenis kelamin yang tidak menderita dan menderita diabetes

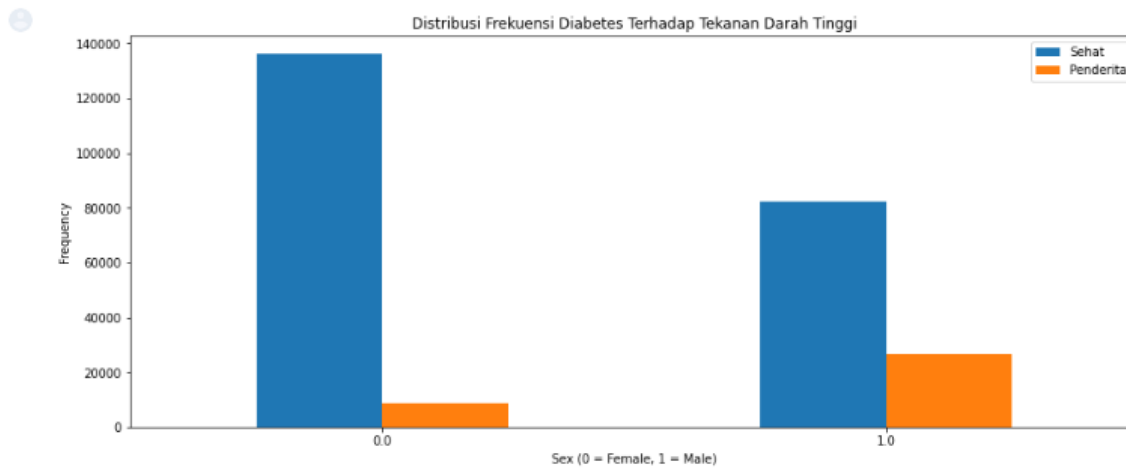
## Hubungan Antara HighBP (tekanan darah tinggi) dengan Penyakit Diabetes (Proses Data dan Visualisasi Data)

```
[ ] pd.crosstab(df.HighBP,df.Diabetes_binary)
```

Diabetes_binary	HighBP	
	0.0	1.0
0.0	136109	8742
1.0	82225	26604

Pada penggabungan kedua hubungan ini dapat dilihat bahwa kebanyakan dari penderita diabetes memiliki tekanan darah tinggi.

```
pd.crosstab(df.HighBP,df.Diabetes_binary).plot(kind="bar",figsize=(15,6))
plt.title('Distribusi Frekuensi Diabetes Terhadap Tekanan Darah Tinggi')
plt.xlabel('Sex (0 = Female, 1 = Male)')
plt.xticks(rotation=0)
plt.legend(["Sehat", "Penderita"])
plt.ylabel('Frequency')
plt.show()
```



Di atas merupakan visualisasi dari distribusi hubungan antara tekanan darah tinggi dengan penderita diabetes




## Hubungan HighChol (Kolesterol) dengan Penyakit Diabetes (Proses Data dan Visualisasi Data)

```
pd.crosstab(df.HighChol,df.Diabetes_binary)
```

Diabetes_binary	HighChol	
	0.0	1.0
0.0	134429	11660
1.0	83905	23686

Dapat dilihat bahwa orang yang memiliki kolesterol tinggi lebih rawan untuk terkena diabetes

```
pd.crosstab(df.HighChol,df.Diabetes_binary).plot(kind="bar",figsize=(15,6))  
plt.title('Distribusi Frekuensi Diabetes Terhadap Kadar Kolesterol Tinggi')  
plt.xlabel('Sex (0 = Female, 1 = Male)')  
plt.xticks(rotation=0)  
plt.legend(["Sehat", "Penderita"])  
plt.ylabel('Frequency')  
plt.show()
```



Visualisasi distribusi frekuensi penderita terhadap HighChol (kadar kolesterol tinggi)

# Hubungan BMI (Indeks Massa Tubuh) dengan Penyakit Diabetes (Proses Data dan Visualisasi Data)


```
pd.crosstab(df.BMI,df.Diabetes_binary)
```

Diabetes\_binary 0.0 1.0

BMI		
12.0	6	0
13.0	19	2
14.0	37	4
15.0	120	12
16.0	328	20
...		
91.0	1	0
92.0	27	5
95.0	11	1
96.0	1	0
98.0	4	3

84 rows x 2 columns

```
pd.crosstab(df.BMI,df.Diabetes_binary).plot(kind="bar",figsize=(40,15))
plt.title('Distribusi Frekuensi Diabetes Terhadap Kadar Kolesterol Tinggi')
plt.xlabel('Sex (0 = Female, 1 = Male)')
plt.xticks(rotation=90)
plt.legend(['Sehat', 'Penderita'])
plt.ylabel('frequency')
plt.show()
```



## Predictive Analysis (Proses Data)

Pada dataset ini, kami ingin menggunakan Random Forest Regressor untuk membuat model prediksi yang berguna untuk memprediksi seseorang yang mengisi survey menderita diabetes atau tidak melalui beberapa faktor yang telah kami cari hubungannya dengan penyakit diabetes sebelumnya.

Double-click (or enter) to edit

```
[ ] from sklearn.model_selection import train_test_split
    from sklearn.ensemble import RandomForestRegressor
    from sklearn.metrics import mean_absolute_error
```

Di atas merupakan import dari library yang akan kami gunakan pada tahap ini, yaitu `train_test_split` yang berguna untuk mengsplit data menjadi data training yang berguna untuk melakukan training terhadap Random Forest Regressor untuk meningkatkan akurasi prediksi dari Random Forest Regressor dan data validasi yang akan digunakan untuk mengvalidasi hasil prediksi dari Random Forest Regressor yang telah dilatih dengan data training.

Lalu ada `mean_absolute_error` yang digunakan untuk mengetahui simpangan kesalahan dari prediksi Random Forest pada data validasi.

+ Code + Text

```
[ ] y = df.Diabetes_binary
    features = ['Age', 'Smoker', 'Sex', 'HighBP', 'HighChol', 'BMI']
    X = df[features]
```

Pada bagian ini kami menentukan faktor apa saja yang dipilih sebagai faktor yang mempengaruhi potensi seseorang dapat menderita diabetes

```
[ ] train_X, val_X, train_y, val_y = train_test_split(X, y, random_state = 0)
```

Melakukan splitting data set untuk digunakan, rasio yang digunakan adalah 75% data untuk training dan 25% untuk testing/validasi

+ Code + Text

```
[ ] forest_model = RandomForestRegressor(random_state=0)
    forest_model.fit(train_X, train_y)
```

```
RandomForestRegressor(random_state=0)
```

Menginisialisasi model prediktif yang akan dibuat, pada analisis ini kami menggunakan Random Forest untuk memprediksi seseorang menderita diabetes atau tidak dari umur, kebiasaan merokok, jenis kelamin, tekanan darah, kadar kolesterol dan BMI.

Disini juga dilakukan training model yang akan kami gunakan dengan data training yang didapat pada splitting sebelumnya

```
diabet_predict = forest_model.predict(val_X)
print(mean_absolute_error(val_y, diabet_predict))
```

```
0.2054869780603688
```

Setelah model dilatih, akan dilakukan pengujian model dengan dataset validasi untuk melihat apakah model yang telah dilatih dapat memprediksi hasil dari dataset validasi secara tepat.

Disini dapat dilihat bahwa terdapat rata-rata error sebesar 0,205.

Untuk lebih jelas dapat dilihat pada file yang telah kami zip dengan nama file `Big_data_Processing_Project_notebookdataset.zip`

## KESIMPULAN

- Dataset yang kami pakai adalah dataset yang berisi data penderita dan orang sehat serta faktor yang mungkin menjadi faktor pendukung utama seseorang terkena diabetes
- Dari dataset diketahui bahwa sebesar 86,07% orang sehat dan terdapat 13,93% menderita diabetes
- Diabetes lebih mungkin diderita seiring umur bertambah
- Wanita lebih beresiko menderita diabetes namun wanita juga sehat daripada pria, hal ini dapat dikarenakan lebih banyak wanita yang mengambil survey ketimbang pria.
- Orang dengan tekanan darah tinggi lebih banyak menderita diabetes
- Orang dengan kolesterol tinggi lebih mungkin menderita diabetes
- Orang yang memiliki BMI 24 - 35 lebih rawan menderita diabetes
- Hasil prediktif analisis kami dengan menggunakan random forest model yang di training dengan 75% data kemudian melakukan validasi dengan 25% sisa data menghasilkan prediksi dengan Mean Absolute Error sebesar 0,205